

Mesure de la qualité d'une extraction d'idées réalisée par un modèle de langue

Application aux consultations publiques à questions ouvertes

Matthias MAZET, Garance MALNOË & Yannis PETIT
encadré.e.s par Cyril FRANÇOIS

Table des matières

1	Introduction	1
1.1	Contexte	1
1.2	Objectif des travaux	2
2	Données et Méthodes	3
2.1	Organisation et gestion de projet	3
2.2	Données	4
2.3	Protocole d'extraction et d'évaluation	5
2.4	Métriques	6
2.5	Pipeline	11
2.6	Impact du changement de LLM	12
3	Résultats et discussion	12
3.1	Extractions et notation humaine	12
3.2	Métrique QualIT	15
3.3	Métrique ROUGE	18
3.4	Métrique NLI	24
3.5	Pipeline	26
3.6	Impact du changement de LLM	27
4	Impact sociétal et environnemental	27
4.1	Politique de la structure d'accueil : Data4Good	27
4.2	Impact environnemental personnel	28
4.3	Impact environnemental global	29
4.4	Impact social global	29
5	Conclusion	31
	Références	33
6	Annexe	34



Tracker de rédaction :

1. Intro
 - (a) Contexte (G) (relu : M)
 - (b) Obj des travaux (G) (relu : M)
2. Données et méthodes
 - (a) Organisations (M) (relu : Y, G)
 - (b) Données (G) (relu : Y, M)
 - (c) Protocole (M) (relu : G)
 - (d) Métriques (Y) (relu : G, M)
 - (e) Pipeline (M) (Relu : Y, G)
 - (f) Comp. LLM (G) (relu : Y)
3. Résultats et dicussion
 - (a) Extractions et notation humaine (M) (Relu : Y, G)
 - (b) QualIT (G)
 - (c) ROUGE (Y) (relu : G) (besoin de discuter sur les commentaires de certaines figures)
 - (d) NLI (Y)
 - (e) Pipeline (M) (relu : G)
 - (f) Comp. LLM (G)
4. RSE
 - (a) Politique de Data4Good (G)
 - (b) Impact env perso (G)
 - (c) Impact env global (G)
 - (d) Impact social global (G)
5. Conclusion (G)

Code couleur :

- A faire
- En cours
- A relire
- A discuter entre nous
- Fini (relu au moins une fois par qqun d'autre que le rédacteur)

Code auteur initial :

- (G) Garance
- (Y) Yannis
- (M) Matthias

1 Introduction

1.1 Contexte

Les consultations publiques représentent de puissants outils pour les élus et les organismes publics, mais également pour les citoyens. En effet, d'une part, elles permettent aux citoyens d'exprimer leurs attentes et leurs priorités et, d'autre part, elles permettent aux décideurs de mieux comprendre le point de vue des masses. Ainsi, ces derniers peuvent récolter de précieuses informations sur des problématiques spécifiques, accéder à leur réalité concrète et aux contraintes du terrain, et en conséquence réduire le décalage souvent perçu entre les politiques publiques implémentées et les besoins réels de la population.

Dans leur forme la plus simple, les consultations publiques s'appuient sur des questions fermées dont la réponse est un score (e.g. entre 1 et 10) ou un "Oui"/"Non". Ce format présente l'avantage d'être simple et très rapide à traiter et analyser. Cependant, les questions fermées présentent des limites évidentes. Prenons l'exemple de la question "Êtes-vous en accord avec la politique actuelle du gouvernement sur l'environnement?". Avec une simple réponse binaire "Oui"/"Non", des individus aux opinions différentes pourraient donner la même réponse, alors que l'un pense que le gouvernement en fait trop sur la législation des pesticides, qu'un autre pense qu'il devrait en faire plus pour le contrôle des gaz à effet de serre, ou qu'un troisième pense qu'il devrait mieux aider lors des rénovations énergétiques. Ainsi, tous se diront en désaccord avec la politique du gouvernement en matière d'environnement, mais pour des raisons très différentes dont le détail est perdu à cause de l'utilisation d'une question fermée.

Face à ce problème apparaît alors la solution des questions ouvertes. En permettant aux contributeurs de s'exprimer librement et de mieux détailler leur point de vue, elles offrent aux commanditaires un aperçu plus riche des opinions exprimées et de la réalité du terrain, et peuvent ainsi favoriser une prise de décision plus adéquate. Elles permettent également de mieux nuancer les réponses, ce qui peut contribuer à dépasser les idées préconçues ou bénéficiant le plus de visibilité dans les médias. Enfin, lorsque les consultations publiques sont perçues comme sincères et suivies d'effets concrets, elles peuvent renforcer le sentiment que la participation individuelle a un impact réel sur les décisions publiques. Ce dernier point est d'autant plus crucial dans un contexte marqué par une abstention électorale élevée et une défiance croissante à l'égard des institutions [AB22, BCR26].

Deux initiatives de consultations publiques à grande échelle ont récemment été menées en France : le Grand Débat National et la Convention Citoyenne pour le Climat, organisées entre 2019 et 2020. Toutes deux avaient pour objectif, aux travers de questions ouvertes, de mieux capter l'opinion des citoyens français, notamment en réaction au mouvement des gilets jaunes de 2018 [BM19]. Ces deux consultations ont toutes deux représenté un coût important : 12 millions d'euros et environ 2 millions de contributeurs pour la première, 5,4 millions d'euros et 150 participants pour la seconde [BM19, Cou20]. Ces chiffres mettent en évidence une des limitations majeures de l'utilisation des questions ouvertes : elles nécessitent un investissement matériel et humain conséquent afin d'assurer la diffusion de l'information, le recueil



FIGURE 1 – Logo de la Convention Citoyenne pour le Climat

des contributions et leur analyse. La démocratie participative a donc un coût qui peut rapidement devenir élevé lorsqu'on souhaite organiser des dispositifs à grande échelle. Une autre problématique de ce type de consultations concerne leur temporalité. Pour qu'une consultation reste pertinente, le recueil et le traitement des avis doivent être réalisés dans un délai raisonnable. Si l'analyse est trop longue, il peut devenir difficile d'agir efficacement (e.g. la fin du mandat du commanditaire), les problématiques soulevées peuvent avoir évolué et des résultats tardifs peuvent fragiliser la confiance entre les participants et les institutions à l'origine de la démarche.

L'analyse manuelle de consultations publiques ouvertes fait donc face à plusieurs défis majeurs : elle est lente, coûteuse et reste sujette aux biais humains. Les outils numériques, et notamment les grands modèles de langues (*Large Language Models*, LLM), constituent une piste de réponse intéressante face à ces contraintes. En effet, ils peuvent automatiser certaines étapes de l'analyse, identifier les idées récurrentes au sein d'un grand nombre de contributions, produire des synthèses thématiques, favoriser une analyse plus transparente et reproductible, et réduire significativement le délai entre la collecte des contributions et la production du rapport final. Bien entendu, l'utilisation d'outils numériques dans le cadre des décisions publiques ne vise pas à remplacer la décision humaine ni à déléguer l'ensemble du processus décisionnel à une intelligence artificielle. Néanmoins, les processus démocratiques et la digitalisation ne sont pas incompatibles, et les associer pourraient contribuer à réduire les contraintes logistiques et administratives inhérentes à l'organisation de consultations à grande échelle. Plusieurs initiatives vont déjà dans ce sens, et nous pouvons notamment en citer deux :

- Le projet ouvert *Plurality*, qui promeut le développement de technologies collaboratives et décentralisées visant à renforcer la participation démocratique, la délibération collective et la protection des droits numériques [WTC26].
- L'outil open source *Talk To The City* d'Objectives AI, qui mobilise des méthodes de traitement automatique du langage pour analyser à grande échelle les contributions citoyennes et structurer les opinions exprimées lors de consultations publiques [Ins26].

1.2 Objectif des travaux




FIGURE 2 – Pipeline global du projet Perspectiva

En théorie, ce protocole permettrait de résumer de manière assez exhaustive les thèmes principaux

Perspectiva, le projet développé par Data4Good et dans lequel s'inscrit nos travaux, se trouve dans la continuité de cette démarche. Il utilise les outils numériques dans le but d'analyser et de mieux comprendre ce qu'un large groupe de personnes peut penser [Cyr]. Il se décline actuellement en deux phases principales : i) l'extraction et l'analyse (type, syntaxe et sémantique) d'idées issues de contributions d'individus à une consultation via un LLM, et ii) le regroupement de ces dites idées en méta-idées plus larges via l'utilisation d'algorithmes de clustering (STS, UMAP20, HDBSCAN, ...) (Figure 2).

exprimés dans un grand nombre de contributions.

Bien que très puissants, les LLM ne sont cependant pas exempts de défauts. Nous observons parfois des hallucinations où la sortie du LLM contient des informations non présentes dans la contribution d'origine, voire fausses. À l'inverse, certaines idées exprimées sont parfois omises ou fragmentées en plusieurs morceaux sans aucun sens. Ce type d'erreurs, qui survient dans la première phase du projet, peut entraîner un certain nombre de problèmes par la suite. Des idées non exprimées pourraient se retrouver dans les méta-idées finales ou, à l'inverse, des idées intéressantes pourraient être perdues à cette étape. Cela conduirait alors à des interprétations erronées et à un bilan final de la consultation peu représentatif des opinions réelles de la population consultée. Ainsi, une problématique majeure de *Perspectiva* est de pouvoir mesurer la qualité des extractions réalisées avec le LLM durant la première phase.

Notre projet tutoré s'est donc articulé autour de la recherche et de la validation de métriques permettant de contrôler les extractions issues de LLM, avec pour objectif final la création d'un pipeline permettant d'extraire, d'évaluer et de sélectionner des idées de consultations publiques. Parallèlement, nous nous sommes aussi intéressés à l'influence du LLM d'extraction sur la qualité du rendu. Nous avons, entre autres, cherché à savoir si un "petit" modèle généraliste suffisait pour réaliser une extraction correcte, ou s'il y avait un réel intérêt à utiliser des gros modèles, au prix de leur forte consommation.

La suite de ce rapport constitue une synthèse de nos travaux, organisée en trois parties : i) présentation des données utilisées, des méthodes mises en place et des métriques étudiées, ii) nos résultats d'extractions, de validation des métriques et d'influence du LLM choisi, et iii) une réflexion sur l'impact environnemental et sociétal de ce projet à différentes échelles.

2 Données et Méthodes

2.1 Organisation et gestion de projet

Ce projet a été réalisé sous la supervision de Cyril François, l'un des membres à l'origine du projet *Perspectiva*. Nous avons travaillé en interaction régulière avec lui, à travers des réunions d'avancement et l'utilisation d'un tableau Kanban permettant de structurer les tâches, de prioriser les objectifs et de suivre l'état d'avancement du projet. En complément de ces échanges, nous organisons également des points hebdomadaires entre membres du groupe. Ces réunions entre nous nous permettaient de faire un état des lieux de l'avancement et d'ajuster la répartition des tâches de manière coordonnée.

L'ensemble du travail (code, scripts d'analyse, documentation et résultats intermédiaires) est accessible sur le [GitHub du projet tutoré](#), dans une logique de transparence et de reproductibilité.

Tous les traitements et analyses ont été réalisés sous Visual Studio Code (v1.109.3) avec Python (v3.13.12). Les principales bibliothèques mobilisées sont : numpy (v2.3.3), ollama (v0.6.0), pandas (v2.3.3), plotly (v6.3.1), requests (v2.32.5), rouge_score (v0.1.2), sentence-transformers (v5.2.2), torch (v2.9.0), tqdm (v4.67.1), transformers (v4.57.1), google (3.0.0) et google-genai (1.64.0). Ces outils ont été utilisés pour le traitement des contributions, l'extraction via des modèles de langue, l'évaluation des sorties et la visualisation des résultats.

2.2 Données

Afin de mener notre analyse de validation de différentes métriques, il était nécessaire de travailler sur un corpus de texte réaliste. Nous avons fait le choix de travailler sur des données issues d'une consultation publique réelle, plutôt que sur des textes artificiellement construits ou excessivement "lissés". En effet, des textes trop homogènes, normés, "parfaits", auraient peu reflété la réalité de la diversité stylistique, lexicale, grammaticale et orthographique observée dans de véritables contributions citoyennes, ce qui aurait limité la capacité de généralisation de nos résultats.

Nous avons ainsi retenu les réponses à la question n°163 du Grand Débat National : "*Que faudrait-il faire pour rendre la fiscalité plus juste et plus efficace ?*", intégrée au thème portant sur la fiscalité. Les contributions sont rédigées en texte libre, sans limite de caractères. Elles n'ont fait l'objet d'aucune modification préalable : les erreurs de syntaxe, de grammaire ou d'orthographe ont été conservées afin de maintenir des conditions d'analyse proche d'une véritable contexte.

Les données utilisées sont accessibles publiquement sur la plateforme gouvernementale [data.gouv](https://data.gouv.fr), et notamment via [le lien dédié au jeu de données utilisé ici](#). L'ensemble des [jeux de données](#) du Grand Débat National sont disponibles sur cette même plateforme, de même que d'autres consultations publiques similaires. Les contributions sont entièrement anonymisées et conformes aux exigences du RGPD, garantissant le respect de la protection des données personnelles.

Taxer davantage les très très riches....On m'a augmenté ma CSG pour la donner à Mr Bernard Arnaud ou à Mr Goshn, cet argent que l'on m'a volé, on l'a volé à mes enfants et petits enfants que je suis obligé d'aider à démarrer dans ma vie, on l'a volé à mes parents âgés car je sois les aider à payer toujours plus, un établissement de retraite décent!!

Contribution n°75

Surtout ne pas rétablir l'ISF, qui nous fait perdre 35 milliards (Monsieur Edouard Philippe le 09 octobre 2017) et qui fait de la France un des seuls pays au monde à posséder encore un tel impôt (IFI). Assez de démagogie

Contribution n°178

Qu'elle frappe en priorité les TRES RICHES : ISF, FLAT TAXE.....TAXER l'EVASION FISCALESupprimer toutes les niches fiscales inefficaces et coûteuses

Contribution n°163

FIGURE 3 – Exemples de contributions

Pour la question étudiée, 154000 contributions sont disponibles (sur environ 186000 participations sur le thème de la fiscalité). Néanmoins, pour des raisons de coûts temporels, computationnels et financiers, notamment liés à l'annotation humaine et aux traitements automatiques, nous avons

restreint notre analyse à un sous-échantillon de 200 contributions. Nous avons retenu les 200 premières entrées du corpus, puis vérifié qu’elles présentaient des caractéristiques globales cohérentes avec l’ensemble du jeu de données, de manière à garantir la représentativité.

La distribution des longueurs de texte étant très déséquilibrée (Figure 4a), nous avons choisi de construire 4 classes arbitraires afin de trier les contributions : très court (<50 tokens), court (51-100 tokens), moyen (101-200 tokens) et long (>200 tokens) (Figure 4b), afin de pouvoir observer, par la suite, si la taille de la contribution avait un impact sur la présence d’hallucinations, d’idées séparées ou sur la validité des métriques.




FIGURE 4 – Analyse descriptive des longueurs des 200 premières contributions

2.3 Protocole d’extraction et d’évaluation

Afin de pouvoir correctement analyser et comparer les différentes métriques sélectionnées, nous avons mis en place un protocole reproductible pour chacune d’entre elles, basé sur la comparaison entre la notation de la métrique avec une notation humaine des extractions d’idées réalisées par le LLM [Rei25]. Nous avons donc procédé comme suit :

1. Extraction des idées de chaque contribution via un LLM.
2. Calcul de la métrique sélectionnée (QualIT, ROUGE, NLI détaillées dans la section suivante) sur chaque extraction.
3. Notation manuelle de l’extraction :
 - a. Chacun des trois membres du groupe note chaque extraction. Pour prévenir au maximum de biais éventuels dû à une notation humaine, nous avons fixé au préalable un ensemble de règles (Encadré 1).
 - b. Marquage de la présence d’hallucinations. Cette notion correspond aux contributions pour lesquelles le LLM a inventé certaines idées (Figure 6).
 - c. Marquage de la présence d’idées séparées. Cette notion correspond aux contributions pour lesquelles le LLM a découpé une idée sans prendre en compte le sens (Figure 7).
4. Calcul des corrélations entre chaque annotateur pour vérifier leur accord.
5. Agrégation des notes humaines en un "score humain" correspondant à la moyenne des trois notes humaines puis ramené entre 0 et 1.

6. Calcul de la corrélation entre le score humain et la métrique sélectionnée.

1. La note doit être comprise entre 0 et 10. Plus la note est élevée, plus l'extraction est de qualité.
2. L'extraction doit contenir le même nombre d'idées que la contribution originale. Aucune idée ne doit être ni ajoutée, ni omise.
3. Les idées extraites doivent garder le même sens que l'idée originale (e.g. une idée négative doit le rester).
4. Les idées extraites doivent être distinctes. Il ne doit pas y avoir de redondance.
5. L'extraction doit être en français.

Encadré 1 – Règles de notation

Nous avons utilisé le modèle de langue (LLM) `llama3:8b-instruct-q4_K_M`, exécuté en local via `ollama`, avec une `temperature` fixée à 0 afin de garantir la reproductibilité des sorties, et un paramètre `top_p` réglé à 0.95 (valeur standard). Ce choix repose sur un compromis méthodologique et computationnel. D'une part, un modèle de 8 milliards de paramètres est suffisamment complet pour comprendre des consignes complètes et produire une sortie au format imposé tout en évitant que la majorité des sorties soient de mauvaise qualité. D'autre part, nous avons également été contraints par la taille du modèle afin de pouvoir l'exécuter en local sur nos machines par manque d'accès à de plus gros serveurs de calcul.

Le prompt employé (Annexe – Figure 24) constitue une adaptation du prompt initial du projet *Perspectiva*. Bien que l'analyse de sentiments (type de phrase, syntaxe et sémantique) ne fasse pas l'objet d'une exploitation dans la suite de ce rapport, nous avons choisi de la conserver dans le prompt afin d'assurer la compatibilité et l'intégrabilité directe de notre travail dans l'architecture globale du projet *Perspectiva*.

Il nous paraît important de souligner que l'objectif, dans cette première phase de l'analyse, n'était pas d'optimiser les performances de l'extraction. Au contraire, nous cherchions explicitement à observer des erreurs d'extraction (hallucinations, fragmentations des idées, déformations sémantiques, ...) afin d'évaluer la capacité des métriques étudiées à détecter et quantifier les différents types de défaillances dans l'extraction. De plus, le choix d'un "petit" modèle de langage était motivé par le besoin d'effectuer une comparaison avec un plus grand modèle dans la suite de nos analyses.

2.4 Métriques

Une métrique d'évaluation est une fonction associant un score à une production textuelle afin de mesurer une propriété donnée. Dans notre cas, l'objectif était d'évaluer la qualité d'une extraction produite par un LLM, c'est-à-dire d'estimer dans quelle mesure les idées extraites restituaient fidèlement les idées contenues dans la contribution d'origine. Toutefois, toutes les métriques ne mesurent pas les mêmes dimensions. Certaines reposent principalement sur le chevauchement lexical entre deux textes (n-grammes communs, recouvrement de tokens), tandis que d'autres cherchent à capturer leur proximité sémantique (proximité de leurs embeddings). Ainsi, une extraction peut obtenir un score élevé selon une métrique fondée sur le recouvrement lexical tout en présentant des défauts notables du point de vue de la cohérence sémantique, des informations contenues et inversement.

Dans ce contexte, nous avons étudié plusieurs métriques reposant sur des fondements méthodologiques distincts afin d’analyser leur capacité à détecter différents types d’erreurs (hallucinations, omissions, fragmentation d’idées, déformations sémantiques, ...). Nous avons présenté ici les trois familles de métriques retenues – QualIT, les métriques ROUGE et les métriques NLI –, chacune correspondant à une approche spécifique de l’évaluation de la qualité d’une extraction.

Métrique QualIT

La première métrique que nous avons étudiée est issue du travail présenté dans le papier *Qualitative Insights Tool (QualIT) : LLM Enhanced Topic Modeling* [KGB⁺24]. Bien que QualIT soit initialement conçu comme un outil de topic modeling intégrant des modèles de langue, il propose également un mécanisme permettant d’évaluer la cohérence globale des éléments extraits par un LLM. Cette propriété en a fait une métrique candidate pour nos analyses, notamment en tant que métrique basée sur une proximité sémantique.

Dans l’approche décrite par les auteurs, l’ensemble des idées extraites d’une contribution est concaténé en un unique texte. La contribution originale et cette concaténation sont ensuite projetées dans un espace d’embeddings (via [sentence-transformers/all-MiniLM-L6-v2](#) produisant des embeddings de dimension 384). On obtient ainsi deux vecteurs de dimension fixe, représentant respectivement le texte original et l’extraction agrégée. La similarité entre ces deux représentations est ensuite calculée à l’aide d’une similarité cosinus (voir ci-après), ce qui permet d’obtenir un score unique pour chaque contribution. Ce score vise à quantifier la proximité sémantique globale entre le texte initial et l’ensemble des idées extraites, indépendamment du chevauchement lexical exact.

$$C_i = \frac{1}{n} \sum_{j=1}^n \frac{V_{inp,ij} \cdot V_{key,ij}}{|V_{inp,ij}| \cdot |V_{key,ij}|}, \text{ avec } \begin{cases} C_i & \text{le score QualIT de la } i^e \text{ contribution.} \\ n & \text{la dimension de l'espace d'embedding.} \\ V_{inp,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding de la} \\ & i^e \text{ contribution.} \\ V_{key,ij} & \text{la } j^e \text{ coordonnée du vecteur d'embedding des idées} \\ & \text{extraites de la } i^e \text{ contribution.} \\ |\cdot| & \text{une norme euclidienne.} \end{cases}$$

Un score élevé indique une forte proximité sémantique globale entre la contribution originale et l’ensemble des idées extraites, tandis qu’un score plus faible suggère une perte d’information, une déformation sémantique ou l’introduction d’éléments non alignés avec le texte source.

Métrique ROUGE

La seconde famille de métriques évaluée est ROUGE (Recall-Oriented Understudy for Gisting Evaluation) [Lin04a]. ROUGE regroupe un ensemble d’indicateurs initialement développés pour l’évaluation automatique de résumés, en comparant un texte généré à un texte de référence à partir de leur recouvrement lexical. Le principe sous-jacent est le suivant : si une extraction est fidèle à la contribution originale, alors une proportion significative des unités lexicales (mots, n-grammes, séquences) présentes dans le texte d’origine devrait également apparaître dans le texte extrait. ROUGE traduit cette idée en mesurant le chevauchement entre les deux textes selon différentes granularités (par exemple, unigrammes pour ROUGE-1, ou plus longues séquences communes pour ROUGE-L).

Dans notre contexte, l'extraction produite par le LLM (ensemble des idées extraites) est considérée comme le texte généré, tandis que la contribution originale joue le rôle de référence. ROUGE permet ainsi de quantifier dans quelle mesure le contenu lexical de l'extraction recouvre celui du texte source. Cette approche est donc, *a priori*, pertinente pour détecter des omissions importantes, les hallucinations ou un appauvrissement lexical, mais elle reste principalement sensible à la surface textuelle et ne capture pas systématiquement les reformulations restant sémantiquement équivalentes.

Ainsi, la métrique ROUGE se décline en plusieurs variantes, correspondant à différentes manières de comparer deux textes :

- **ROUGE-N** : mesure le chevauchement de n -grammes (séquences de n mots) entre la référence et le texte généré. Dans notre cas, nous utilisons $n = 1$ (ROUGE-1), ce qui revient à comparer le recouvrement en unigrammes.
- **ROUGE-L** : se base sur la *plus longue sous-séquence commune* (*Longest Common Subsequence*, LCS), ce qui permet de capturer une similarité en séquence sans imposer que les mots soient strictement consécutifs.
- **ROUGE-S / ROUGE-SU** : repose sur des *skip-bigrammes*, c'est-à-dire des paires de mots apparaissant dans le même ordre, possiblement séparés par d'autres mots (avec ou sans unigrammes).

Les scores ROUGE sont compris entre 0 et 1. Un score proche de 1 indique une forte similarité entre les deux textes, tandis qu'un score proche de 0 suggère une faible similarité. Dans ce projet, notre objectif n'était pas d'évaluer une correspondance strictement *mot-à-mot*, puisqu'une extraction de qualité peut reformuler le texte original tout en en conservant le sens. Néanmoins, ROUGE constitue une approche pertinente : elle est simple à implémenter, rapide à calculer et largement utilisée dans la littérature, ce qui facilite l'interprétation et la comparaison des résultats. Ces propriétés en ont fait une bonne métrique candidate pour nos analyses, notamment en combinaison avec la métrique QualIT.

Nous avons retenu deux variantes : ROUGE-1 et ROUGE-L. L'implémentation repose sur la librairie `rouge_score` en Python. Pour chaque contribution, nous avons comparé le texte original (`contribution`) au texte d'extraction agrégé (`ideas_text`). Nous avons conservé la mesure F_1 (désignée comme *F-measure* dans la librairie), qui combine précision et rappel et permet de limiter certains effets liés aux différences de longueur entre les textes [Lin04b]. En cas d'erreur de parsing (extraction vide, format non conforme), nous avons attribué un score nul afin d'éviter toute surestimation artificielle des performances.

Métrique NLI

La troisième métrique étudiée repose sur le cadre du *Natural Language Inference* (NLI). Elle s'inscrit dans les travaux en inférence textuelle dont l'objectif est de déterminer, à partir d'une prémisses p et d'une hypothèse h , la relation inférentielle qui les relie. La prémisses p constitue le texte de référence, décrivant une situation et un ensemble d'informations supposées vraies pour les besoins de l'évaluation, tandis que l'hypothèse h est un second énoncé dont on cherche à établir le statut relativement à p .

Trois relations sont classiquement distinguées (Figure 5) :

- **Entailment (E)** : l'hypothèse h est entraînée par p , c'est-à-dire que dans toute situation compatible avec p , h est également vraie.
- **Contradiction (C)** : l'hypothèse h est incompatible avec p ; si p est vraie, alors h doit être fausse.
- **Neutral (N)** : l'hypothèse h n'est ni entraînée ni contredite par p ; la vérité de h reste indéterminée relativement à p .




FIGURE 5 – Exemple des relations NLI

Dans l'analyse proposée par Blanck, Noble et Chatzikyriakidis [BNC26], ces relations ne doivent pas être comprises comme de simples catégories empiriques, mais comme de véritables relations d'inférence dont l'interprétation dépend du cadre logique adopté (conditionnelle matérielle, conditionnelle stricte modale, lecture avec import existentiel, etc.). Ainsi, la distinction entre *entailment*, *contradiction* et *neutral* repose sur des critères sémantiques précis et non uniquement sur une similarité lexicale. Deux phrases peuvent partager de nombreux mots sans entretenir de relation d'entailment, tandis qu'une paraphrase peut être logiquement équivalente malgré un faible recouvrement lexical. Autrement dit, il ne s'agit pas uniquement d'évaluer si les deux textes "se ressemblent", mais aussi de déterminer si l'un implique logiquement l'autre.

Les propriétés du cadre NLI sont donc pertinentes dans notre contexte, où nous cherchions à vérifier si les idées extraites par le LLM sont bien soutenues par la contribution originale, et à pénaliser les cas où le LLM inversait le sens (par exemple via une négation) ou introduisait des éléments qui n'étaient pas présents. L'enjeu est d'évaluer la fidélité sémantique d'une extraction, indépendamment des variations de surface textuelle.

La tâche NLI peut être vue comme l'apprentissage d'une fonction qui associe à chaque paire d'énoncés une relation inférentielle :

$$f : (p, h) \mapsto \{E, C, N\}.$$

Dans l'idéal, cette classification est réalisée à l'aide d'un NLI entraîné spécifiquement pour la tâche considérée. Afin d'éviter l'entraînement local d'un réseau de neurones, une opération coûteuse en temps de calcul et en ressources matérielles, nous avons fait le choix d'utiliser un modèle NLI pré-entraîné de référence. Plus précisément, nous avons retenu le modèle `ynie/roberta-large-snli_mnli_fever_anli_R1_R2_R3-nli`, disponible sur la plateforme Hugging Face, entraîné sur plusieurs corpus standards de NLI (SNLI, MNLI, FEVER et ANLI).

Néanmoins, notre démarche initiale a consisté à reproduire l'intuition sous-jacente au NLI sans recourir à un réseau de neurones. Nous avons donc implémenté une approximation de cette intuition, que nous avons ensuite comparée au réseau de neurones pré-entraîné.

Cette implémentation repose sur la combinaison de deux mesures complémentaires de similarité textuelle : un score de Jaccard, qui capture le recouvrement lexical entre la contribution et l'extraction, et une mesure LCS, qui tient compte de l'ordre relatif des termes. La première reflète la proximité de contenu, tandis que la seconde permet de préserver une cohérence séquentielle. Cette combinaison se justifie notamment par la formalisation de la composante LCS qui vise à approximer une relation d'entailment par des indices de similarité de surface [Lin04a].

Nous avons donc implémenté une approximation lexicale de type NLI, en respectant l'idée suivante : une idée extraite est d'autant plus fiable qu'elle présente une forte similarité avec au moins une phrase de la contribution, et qu'elle ne contredit pas cette phrase.

Calcul du score de support. Nous découpons d'abord la contribution en phrases $\{p_j\}$ (ponctuation forte et retours à la ligne) qui correspondront aux prémisses, et nous considérons les idées extraites $\{h_i\}$ obtenues par le LLM comme les hypothèses. Pour chaque idée h_i , nous calculons un score de similarité avec chacune des phrases p_j et nous conservons le meilleur appariement :

$$\text{support}(h_i) = \max_j (0.6 \cdot J(h_i, p_j) + 0.4 \cdot \text{LCS}(h_i, p_j)),$$

Le score de Jaccard $J(h_i, p_j)$ est défini comme :

$$J(h_i, p_j) = \frac{|T(h_i) \cap T(p_j)|}{|T(h_i) \cup T(p_j)|},$$

où $T(\cdot)$ désigne l'ensemble des tokens du contenu (après suppression d'une liste minimale de mots-outils). Ce score mesure le recouvrement lexical entre les deux ensembles. La composante $\text{LCS}(h_i, p_j)$ correspond à un ratio basé sur la *longest common subsequence* (plus longue sous-séquence commune), qui capture une similarité séquentielle en tenant compte de l'ordre relatif des mots. Elle est ici implémentée via la classe `SequenceMatcher` de la bibliothèque standard Python.

Le score final $\text{support}(h_i)$ est compris entre 0 et 1. Plus il est élevé, plus l'idée h_i est lexicalement proche d'au moins une phrase de la contribution.

Pénalisation des contradictions par négation. Afin de détecter une éventuelle inversion de polarité (mots similaires mais sens inversé), nous introduisons une fonction booléenne $\text{neg}(\cdot)$ qui détecte la présence d'un marqueur explicite de négation : " ne ", " n' ", " pas ", etc.

Nous définissons $j^* = \arg \max_j (0.6 \cdot J(h_i, p_j) + 0.4 \cdot LCS(h_i, p_j))$, c'est-à-dire l'indice de la phrase présentant le support maximal. On note alors p_{j^*} la phrase la plus similaire à h_i .

Si la polarité diffère entre h_i et p_{j^*} , nous appliquons une pénalité :

$$\text{contra}(h_i) = \mathbf{1} [\text{neg}(h_i) \neq \text{neg}(p_{j^*})] \cdot (1 - \text{support}(h_i)) \cdot \alpha,$$

où $\alpha \in [0, 1]$ est un facteur de pénalisation. Nous avons fixé $\alpha = 0.8$ dans nos expériences, cette valeur a été retenue sur la base des résultats obtenus lors de nos expérimentations, dans le but d'assurer un compromis entre détection des contradictions et cohérence du score final.

Si une idée est peu supportée par le texte et qu'elle inverse la polarité via une négation, il est probable qu'elle corresponde à une hallucination ou à une mauvaise reformulation. Ainsi, en théorie, cette approximation lexicale de type NLI devrait pouvoir détecter avec aisance les hallucinations d'un LLM.

Score final. Pour chaque contribution p , nous agrégeons ensuite les scores sur l'ensemble des idées extraites $\{h_1, \dots, h_n\}$. Nous calculons :

$$NLI_{\text{support}}(p) = \frac{1}{n} \sum_{i=1}^n \text{support}(h_i)$$

$$NLI_{\text{contra}}(p) = \frac{1}{n} \sum_{i=1}^n \text{contra}(h_i)$$

$$NLI_{\text{final}}(p) : \max [0, \min [1, NLI_{\text{support}}(p) - NLI_{\text{contra}}(p)]]$$

Ce score final est compris entre 0 et 1. Un score élevé correspond à des idées globalement bien supportées par la contribution et ne présentant pas d'inversion évidente du sens via la négation.

Il convient néanmoins de souligner que cette approximation NLI présente plusieurs limitations. Elle nécessite que la contribution puisse être bien découpée en phrases $\{p_j\}$ et que chaque idée soit comprise dans une seule phrase. De plus, elle ne capture ni les inférences pragmatiques, ni les reformulations sémantiques profondes, ni les phénomènes de paraphrase complexe.

2.5 Pipeline

Afin de permettre une réutilisation complète et rapide de nos travaux, nous avons construit un pipeline de traitement des contributions. À partir d'un LLM et d'un prompt donné, ce pipeline permet d'extraire les idées contenues dans chaque contribution, de réaliser l'analyse de sentiments, puis de retourner un jeu de données structuré et concaténé pour chaque contribution. Ce pipeline intègre également le calcul des différentes métriques présentées précédemment. Il permet de produire soit un jeu de données brut (incluant l'ensemble des extractions), soit un jeu filtré, dans lequel les contributions associées à des extractions jugées de faible qualité, selon des seuils définis sur les scores des métriques, sont exclues. L'ensemble du processus, depuis l'appel au modèle jusqu'à la mise en forme des sorties, est ainsi intégré dans une unique chaîne de traitement.

Au-delà de cet aspect opérationnel, le pipeline a pour objectif de combiner l'effet des différentes métriques analysées. Comme discuté précédemment, ces métriques mesurent des propriétés

distinctes (recouvrement lexical, proximité sémantique globale, ...). Leur agrégation permettait ainsi d’obtenir une évaluation plus robuste et plus nuancée de la qualité d’une extraction qu’une métrique seule. Cette approche vise ainsi à obtenir l’évaluation la plus complète possible des idées extraites par rapport au texte source.

2.6 Impact du changement de LLM

Comme indiqué en introduction, notre analyse n’a pas porté uniquement sur la pertinence intrinsèque des métriques, mais également sur l’influence du modèle d’extraction choisi. L’objectif est double. D’une part, il s’agit d’évaluer empiriquement si l’utilisation d’un modèle de plus grande capacité permet effectivement d’obtenir des extractions de meilleure qualité qu’un modèle plus léger et généraliste. D’autre part, nous cherchons à vérifier si les métriques étudiées, et plus largement le pipeline qui les agrège, sont sensibles à cette différence de qualité, c’est-à-dire si elles attribuent effectivement de meilleurs scores aux extractions produites par un modèle plus performant.

Pour cela, nous avons reproduit le protocole d’évaluation en remplaçant le modèle d’extraction initial par un modèle de plus grande taille. Les 200 contributions sélectionnées ont été soumises à une nouvelle extraction, puis celles-ci ont été annotées manuellement (score, hallucinations, idées séparées). Afin de réduire les coûts temporels, une seule personne a réalisé cette seconde annotation. Nous avons fait ce choix suite au constat d’un fort accord entre les annotateurs lors de la phase d’évaluation avec le premier modèle.

Les extractions obtenues ont ensuite été évaluées selon le même protocole que précédemment : application du score QualIT, calcul des métriques ROUGE et évaluation par NLI (à la fois via notre approximation lexicale et via le modèle pré-entraîné).

Le modèle utilisé pour cette seconde extraction est **Gemini 3 Pro** (version preview), un modèle de grande taille. Nous avons pu accéder à ce modèle via le compte *Vertex AI* (Google) de notre tuteur et dont l’utilisation est payante, ce qui introduit une contrainte budgétaire non négligeable. L’intégration a été réalisée en Python à l’aide des bibliothèques `genai` et `google.oauth2`.

3 Résultats et discussion

3.1 Extractions et notation humaine

Comme énoncé précédemment, nous avons travaillé sur les 200 premières contributions non vides parmi celles disponibles dans les données relatives à la question n°163 du Grand Débat National.

Un certain nombre de ces extractions présentaient des problèmes. Nous avons notamment identifié deux grandes classes d’erreurs :

1. Le LLM hallucine, c’est-à-dire qu’il invente des idées non présentes dans la contribution originale, mais dont le sens découle généralement d’autres idées bien présentes (Figure 6).
2. Le LLM découpe une idée ou une phrase de manière plus ou moins incohérente. Cette situation arrive souvent en présence de pronom ou de conjonction de coordination, la phrase est séparée en deux mais les idées extraites ne peuvent pas être comprises indépendamment (Figure 7).




FIGURE 6 – Exemple d’hallucination du LLM




FIGURE 7 – Exemple d’idées séparées par le LLM

Ces deux cas de figure sont typiquement le genre d’erreur que nous souhaitons qu’une bonne métrique soit en mesure de détecter. Nous avons donc pris soin de bien marquer leur présence lors de la notation humaine.

Par un calcul de corrélation, nous avons donc vérifié notre accord, et nous étions généralement tous en accord (corrélation > 0.9 à chaque fois) (Table 1).

	Garance	Matthias
Garance		0.93
Yannis	0.93	0.94

TABLE 1 – Corrélation des notes entre annotateurs du groupe

Nous avons donc agrégé les trois notes via une moyenne standard. Nous obtenons finalement un "score humain" moyen d’environ 0.54, avec une médiane à 0.6, un minimum à 0 et un maximum à 1 (Annexe - Figure 25).

En nous intéressant au score humain moyen dans chacune des catégories de longueur de contribution, nous avons pu remarquer la présence d’une dégradation de qualité pour les longues contributions tandis que nous pouvions observer initialement une amélioration du score moyen entre le passage des contributions très courtes à courtes puis de taille moyenne (Figure 8).





FIGURE 8 – Score humain moyen selon la catégorie de longueur


Nous avons observé un taux d'hallucination assez élevé pour les très courtes contributions (>0.4) et pour les courtes contributions (>0.2) (Figure 9a). Dans les faits, nous avons surtout observé que pour les courtes contributions, le LLM avait tendance à ajouter plusieurs idées très proches, que l'on pourrait aisément attribuer à un individu ayant écrit la contribution considérée. Cet effet semble s'estomper pour les contributions plus longues.

Nous avons relevé, à l'inverse, que les contributions très courtes étaient légèrement moins touchées par les idées séparées (ou invalides) que les contributions plus longues (Figure 9b). Ceci peut sans doute s'expliquer par le fait que les contributions très courtes soient simplement trop courtes pour être séparables.

Taux d'hallucinations par catégories de longueur



Taux d'idées invalides par catégories de longueur



(a) Taux hallucinations selon catégories de longueur (b) Taux hallucinations selon catégories de longueur

FIGURE 9 – Analyse descriptive des longueurs des 200 premières contributions

3.2 Métrique QualIT

Résultats généraux




FIGURE 10 – Enter Caption

Score moyen : 0.78. Corrélation de Pearson avec score humain : 0.71. Corrélation de Spearman avec le score humain : 0.72.

Impact de la longueur du texte




FIGURE 11 – Enter Caption

Impact des hallucinations




FIGURE 12 – Enter Caption

Impact des idées séparées




FIGURE 13 – Enter Caption

Explications

Idées séparées :




FIGURE 14 – Schéma d’un exemple d’échec de détection des idées séparées par QualIT à cause de la présence d’une conjonction de coordination




FIGURE 15 – Schéma d’un exemple d’échec de détection des idées séparées par QualIT à cause de la présence d’un pronom

Hallucinations :




FIGURE 16 – Schéma d’un exemple d’échec de détection des hallucinations par QualIT

3.3 Métrique ROUGE

3.3.1 Résultats L-ROUGE

Les scores ROUGE-L obtenus ont mis en avant une corrélation plutôt positive avec la notation humaine. Nous avons obtenu une corrélation de Pearson entre les scores ROUGE-L et la notation humaine de 0.78 et une corrélation de Spearman de 0.72, soit des résultats très similaires à ceux obtenus par la métrique QualIT.

Au global, nous avons bien observé une relation linéaire positive entre le score humain et le score ROUGE-L (Figure 17) : les contributions ayant un score ROUGE-L élevé ont été majoritairement associées à des notes humaines élevées. Inversement, les extractions de faible qualité ont présenté généralement des scores ROUGE-L faibles, ce qui pourrait indiquer une certaine capacité à détecter les hallucinations qui sont souvent associées à des scores humains faibles.

Néanmoins, nous avons également observé une dispersion notable autour de la droite $\text{score humaine} = 10 \times \text{score ROUGE-L}$, notamment pour les scores intermédiaires (entre 0.2 et 0.8). Nous relevons autant la présence de sur-notations que de sous-notations contrairement à la métrique QualIT où nous avons essentiellement observé une sur-notation. Ceci suggère que ROUGE-L capture efficacement le recouvrement séquentiel de surface : les extractions qui correspondent totalement ou pas du tout, mais ne permet pas toujours de distinguer des reformulations correctes de modifications sémantiques plus subtiles.

heatmap de la relation entre le score humain et la métrique ROUGE-L




FIGURE 17 – heatmap de la relation entre la métrique ROUGE-L et le score humain

Impact des hallucinations L'analyse en fonction de la présence d'hallucinations (Figure 18) a confirmé cette intuition quant à la capacité de la métrique à « capturer » les hallucinations. Les contributions pour lesquelles une hallucination avait été identifiée manuellement (en rouge sur la figure) se concentraient majoritairement dans la zone correspondant à des scores ROUGE-L faibles et à des notes humaines basses. Bien sûr, nous n'observons pas une parfaite concordance entre la note humaine et la note fournie par la métrique pour l'ensemble des hallucinations, mais nous pouvons noter une amélioration nette par rapport à QualIT sur cette problématique. Cela signifie donc que ROUGE-L parvient relativement efficacement à pénaliser les extractions comportant des hallucinations.

Relation entre le score humain et la métrique ROUGE-L



FIGURE 18 – Relation entre la métrique ROUGE-L et le score humain selon la présence d'hallucination

Impact de la longueur des contributions L'analyse par catégorie de longueur (Figure 19) a mis également en évidence un effet notable de la taille des contributions. Les contributions courtes et moyennes ont présenté en moyenne des scores ROUGE-L plus élevés que les longues contributions (score moyen de 0.7 contre < 0.35), ce qui correspond aux résultats que nous avons pu observer précédemment pour le score humain et la métrique QualIT. Cette effet peut sans doute s'expliquer par le fait que, dans des textes plus longs, la probabilité d'omission partielle ou de fragmentation d'idées augmente, ce qui réduit mécaniquement le recouvrement séquentiel global.




FIGURE 19 – Score moyen ROUGE-L selon la longueur des contributions (en tokens)

Dans l'ensemble, ROUGE-L a donc semblé constituer une métrique pertinente pour détecter les erreurs « grossières » d'extraction et les hallucinations. Néanmoins, son caractère fondé sur la similarité de surface limite sa capacité à capturer des écarts sémantiques plus subtils, ce qu'on retrouve généralement dans les contributions les plus longues (> 200 tokens).

3.3.2 Résultats 1-gram ROUGE

Les scores ROUGE 1-gram ont présenté également une corrélation positive avec la notation humaine : nous avons relevé une corrélation de Pearson de 0.79 et une corrélation de Spearman de 0.73. Ces valeurs sont très proches de celles obtenues avec QualIT et ROUGE-L, la proximité des scores avec ROUGE-L peut sans doute s'expliquer par la proximité des deux métriques.

Nous avons observé (Figure 20) une relation croissante entre ROUGE-1 et le score humain, similairement à la relation observée pour ROUGE-L, mais avec une dispersion légèrement plus marquée pour certaines valeurs intermédiaires (score 1-gram entre 0.2 et 0.8) **A discuter, la différence ne me saute pas vraiment aux yeux.**

Cette caractéristique s'explique par la construction de chacune des métriques. Contrairement à ROUGE-L qui prend en compte la plus longue séquence commune, ROUGE-1 repose uniquement sur le recouvrement lexical en unigrammes. Ainsi, dès lors qu'une extraction reprend une proportion importante des mots du texte original, le score ROUGE 1-gram demeure élevé, même si la structure globale est altérée ou si certaines idées sont mal articulées, tandis que ROUGE-L pénalise davantage les modifications affectant l'ordre ou la cohérence séquentielle.

heatmap de la relation entre le score humain et la métrique ROUGE-1




FIGURE 20 – Heatmap de la relation entre la métrique ROUGE 1-gram et le score humain

Impact des hallucinations L'analyse selon la présence d'hallucinations a pu confirmer la capacité de la métrique ROUGE 1-gram à détecter efficacement les cas d'erreurs : les contributions annotées comme comportant une hallucination se situent majoritairement dans la zone de faibles scores (Figure 21). Toutefois, par comparaison avec ROUGE-L **A discuter, de nouveau, pas de différence notable pour moi**, on observe que certains cas intermédiaires conservent un score relativement élevé lorsque les mots-clés sont présents, même si l'organisation ou le sens exact de l'extraction est partiellement altéré.

Relation entre le score humain et la métrique ROUGE-1




FIGURE 21 – Relation entre la métrique ROUGE 1-gram et le score humain selon la présence d'hallucination

Impact de la longueur des contributions L'effet de la longueur des contributions suit, de nouveau, une tendance comparable à celle observée avec le score humain (et ROUGE-L) : les textes courts et moyens obtiennent en moyenne de meilleurs scores que les textes longs (Figure 22). Néanmoins, l'écart entre catégories apparaît légèrement plus marqué pour ROUGE 1-gram, ce qui confirme sa sensibilité au recouvrement proportionnel de mots. Dans les contributions longues, la moindre omission réduit mécaniquement la proportion de tokens communs, entraînant une baisse plus nette du score.




FIGURE 22 – Score moyen ROUGE-1 selon la longueur des contributions (en tokens)

Dans l’ensemble, ROUGE 1-gram et ROUGE-L fournissent des résultats cohérents et proches en termes de corrélation avec l’évaluation humaine. ROUGE 1-gram se distingue par sa simplicité et sa sensibilité au recouvrement lexical direct, tandis que ROUGE-L introduit une contrainte séquentielle supplémentaire. Les deux métriques restent toutefois limitées à une analyse de surface et ne permettent pas, à elles seules, de capturer pleinement les écarts sémantiques plus subtils.

Métrique	Cor. Pearson	Cor. Spearman	Score moyen	Score médian	Score moy. (H)	Score moy. (¬H)
QualIT	0.71	0.72	0.78	0.85	0.71	0.90
ROUGE-1 (F1)	0.79	0.73	0.60	0.66	0.37	0.79
ROUGE-L (F1)	0.78	0.72	0.56	0.60	0.33	0.75

TABLE 2 – Synthèse quantitative des métriques : corrélations avec la note humaine et statistiques descriptives des scores. H = contributions avec hallucination.

3.4 Métrique NLI

Afin d’évaluer la qualité des extractions de la métrique NLI, nous nous intéressons à trois scores distincts issue de celle-ci :

1. Le score moyen d’**entailment** :

$$NLI_{\text{support}}$$

2. Le score moyen de 1– **contradiction** :

$$1 - NLI_{\text{contra}}$$

3. Le score combiné défini par :

$$NLI_{\text{final}} = \max(0, \min(1, NLI_{\text{support}} - NLI_{\text{contra}}))$$

La première mesure capture directement le degré de soutien sémantique. La seconde pénalise explicitement les contradictions. La troisième cherche à combiner ces deux dimensions en favorisant les idées fortement soutenues tout en pénalisant celles qui présentent une incompatibilité explicite.

L’objectif de cette métrique NLI est de maximiser l’entailment tout en minimisant la contradiction de l’extraction. Toutefois, dans un contexte d’évaluation automatique, ces deux indicateurs ne sont pas nécessairement symétriques. Une idée peut être faiblement soutenue sans pour autant être contradictoire (cas neutre), tandis qu’une contradiction explicite constitue une indication forte de mauvaise qualité d’extraction d’idée.

Pour cette raison, bien que nous présentions les résultats pour les trois mesures, nous allons notamment étudier les résultats du score NLI_{final} , intégrant en même temps le soutien sémantique et la pénalisation des contradictions. Cette formulation permet de mettre en avant l’objectif de notre étude : mesurer la qualité des idées extraites conformément à la contribution de base.

3.4.1 Résultats NLI

Les trois scores de la métrique NLI présentent toutes des corrélations positives mais assez différentes. Nous obtenons comme corrélation de Pearson 0.61, 0.28, 0.52 et comme corrélation de Spearman 0.62, 0.24 et 0.51 respectivement pour les scores $NLI_{\text{support},1} - NLI_{\text{contra}}$ et $NLI_{\text{support}} - NLI_{\text{contra}}$.

Le score NLI_{support} obtient la corrélation la plus élevée avec l’évaluation humaine. Ce résultat indique que le degré de soutien sémantique constitue un indicateur un assez fiable de la qualité d’extraction.

Toutefois, le score $1 - NLI_{\text{contra}}$ présente une corrélation nettement plus faible que les deux autres scores : cette asymétrie indique que l’absence de contradiction n’est pas gage de qualité des extractions d’un LLM.

En ce qui concerne NLI_{final} , elle présente une corrélation intermédiaire aux deux précédentes. Concrètement, cela signifie que la plupart des erreurs observées dans les extractions relèvent davantage d’un manque de soutien explicite que de contradictions.

Heatmap de la relation entre le score humain et la métrique NLI (final)




FIGURE 23 – Heatmap de la relation entre la métrique NLI_{final} et le score humain

La heatmap (Figure 23) met en avant une tendance globale croissante entre NLI_{final} et le score humain, avec une dispersion notable, en particulier pour les valeurs intermédiaires du score NLI. Contrairement aux métriques ROUGE, où la dispersion était principalement liée à des phénomènes de recouvrement lexical partiel, la dispersion observée ici semble refléter des cas où le modèle NLI attribue un niveau modéré d’entailment à des extractions pourtant jugées faibles par les annotateurs humains.

3.4.2 Résultats NLI-Roberta

3.5 Pipeline

Nous avons construit un pipeline avec pour objectif d’avoir un maximum de flexibilité sur sa réutilisation. Il se construit avec les arguments suivants :

- `df` : Le jeu de données à analyser.
- `system_prompt` : Le prompt système pour le LLM.
- `user_template` : Le template utilisateur pour le LLM.
- `extract_model` : Le LLM pour l’extraction (avec par défaut celui que nous avons utilisé, "llama3 :8b-instruct-q4_K_M").
- `embed_model` : le modèle de sentence-transformers pour les embeddings (avec par défaut "sentence-transformers/all-MiniLM-L6-v2").
- `return_intermediate` : un argument binaire pour préciser si nous souhaitons aussi le jeu de données avec l’analyse de sentiments (défaut = False).
- `error_filter` : Un argument binaire pour filtrer ou non les erreurs de parsing (défaut = "Oui").
- `qualit_filter` : Le score QualIT minimal pour qu’une extraction soit conservée (défaut = 0 : pas de filtre).

- `rouge1_filter` : Le score ROUGE 1-gramme minimal pour qu'une extraction soit conservée (défaute = 0 : pas de filtre).
- `rougeL_filter` : Le score ROUGE L minimal pour qu'une extraction soit conservée (défaute = 0 : pas de filtre).

Le pipeline proposé peut être mobilisé de plusieurs manières complémentaires. Tout d'abord, il constitue un cadre expérimental permettant de comparer différents LLMs ou différentes stratégies de prompt afin d'évaluer leur capacité à extraire correctement les idées contenues dans les contributions en comparant les scores. Aspect dont nous nous sommes servis pour l'évaluation de l'impact du changement de LLM. De plus, il peut servir à la construction de jeux de données présentant différents niveaux de qualité. En choisissant des seuils plus sévères, il est possible des jeux de données ne contenant que des extractions jugées très fiables. Cet aspect permet de contrôler explicitement le compromis entre couverture et précision.

3.6 Impact du changement de LLM

A venir.

Quelques notes :

- Toutes les erreurs sont liés au fait que le LLM ait pas répondu à temps (compter).
- Très très efficace pour la synthèse, pour les très très longues contributions il parvient à ne garder que les idées vraiment pertinentes et à enlever le superflux, les exemples ce que ne faisait pas le 1er LLM.
- Tableau avec score humain moyen, cardinal hallu, cardinal idées séparées, score moyen qualit, score moyen rouge-1, score moyen rouge-l, score moyen nli à la main, score moyen nli pré-entraîné

4 Impact sociétal et environnemental

4.1 Politique de la structure d'accueil : Data4Good

Nous avons réalisé notre projet au sein de l'association *Data For Good* [sit26], un collectif rassemblant plus de 7,000 bénévoles (data scientists, data engineers, développeurs, designers, etc.) mettant leurs compétences numériques au service de l'intérêt général. L'association repose sur un modèle collaboratif : les équipes se constituent autour de projets thématiques, souvent en collaboration avec des acteurs publics ou associatifs comme ANTICOR ou OXFAM. Elle concentre son action sur trois axes principaux : climat et biodiversité, démocratie et citoyenneté, justice sociale. Data for Good se positionne explicitement sur des enjeux sociaux et environnementaux majeurs.

Sur le plan écologique, cet engagement se traduit de deux façons. D'une part, plusieurs projets visent directement à produire des outils d'analyse et de transparence sur des problématiques environnementales (surpêche, énergies fossiles, déforestation, impact environnemental de l'alimentation, etc). D'autre part, son organisation en interne réduit fortement son empreinte écologique : l'absence de locaux entraîne l'absence de déplacements domicile-travail et supprime les coûts énergétiques liés au chauffage ou à la climatisation, et la coordination au sein des différents projets est gérée via des outils numériques (GitHub, Slack, ...). Ainsi, l'empreinte de la structure est faible

en comparaison avec celle d’une organisation classique.

Sur le plan social, l’association s’investit dans des projets qui favorisent l’intégration des personnes réfugiées, accompagnent celles en situation de précarité, luttent contre les cyberviolences et les discriminations, ou cherchent à renforcer la transparence démocratique. Les initiatives sur la désinformation, les biais algorithmiques ou la justice fiscale visent à enrichir le débat public et à mieux faire comprendre les mécanismes institutionnels.

Ainsi, la structure dans laquelle s’inscrit notre projet est déjà très vertueuse de par son positionnement et son organisation. Cependant, l’impact environnemental du numérique, notamment lorsqu’on utilise le cloud ou des modèles d’intelligence artificielle particulièrement gourmands en ressources, n’est pas totalement négligeable. Pour aller plus loin, il serait pertinent de mesurer précisément l’empreinte écologique de chaque projet ou de définir une politique claire de sobriété numérique.

4.2 Impact environnemental personnel

L’impact environnemental de notre projet en tant que tel reste assez limité. L’ensemble des réunions (environ une dizaine, d’une durée d’1h-1h30) se sont toujours déroulées à distance, ce qui a permis d’éviter tout déplacement en voiture ou même en transports en commun. Bien que les visioconférences impliquent une consommation énergétique liée à l’utilisation des ordinateurs et au trafic de données, cette consommation reste généralement inférieure à celle qu’aurait engendré des déplacements répétés, notamment en voiture individuelle.

Pour ce projet, nous avons travaillé sur nos trois ordinateurs personnels. L’électricité consommée correspond à un usage classique : traitement de données, rédaction et réunions en ligne. L’extraction d’idées, n’a représenté qu’une très faible partie de notre activité. Aucun de nos équipements n’a été acheté spécifiquement pour ce projet, nous ne pouvons donc vraiment lui attribuer l’impact de leur fabrication..

Pour une partie des traitements, nous avons utilisés des infrastructures distantes, comme Google Cloud Platform (VertexAI), et des service en ligne tels que GitHub ou Google Drive pour l’hébergement des fichiers de code ou les notes de réunions. Ceci implique donc des centres de données et donc de la consommation d’énergie. Quand bien même l’impact de ces services reste modeste, leur usage contribue tout de même à l’empreinte globale du projet.

Le projet s’est également appuyé sur l’utilisation de modèles pré-entraînés pour l’extraction d’idée et pour la seconde partie de la métrique NLI. L’entraînement initial de ces modèles demande beaucoup d’énergie, mais cet impact est partagé entre tous les utilisateurs. Pour notre projet, seule la phase d’inférence compte vraiment, et elle reste très faible vu le nombre limité de contributions et d’idées analysées. .

Enfin, nous nous sommes appuyés sur des outils d’intelligence artificielle pour nous assister dans l’écriture de code et la rédaction du rapport. Ces outils impliquent une consommation énergétique supplémentaire, néanmoins, nous avons essayé d’en faire une utilisation plutôt sobre en y recourant qu’en cas de véritable blocage et non pas comme premier réflexe.

Dans l'ensemble, l'empreinte environnementale du projet à petite échelle provient principalement de la consommation électrique des équipements informatiques et de l'usage d'infrastructures cloud.

4.3 Impact environnemental global

Même si notre l'empreinte environnementale directe de notre projet reste modérée (comme évoqué dans la section précédente), nous ne pouvons pas nous limiter à cette observation. En effet, notre projet s'inscrit dans un écosystème numérique plus large, dont l'empreinte, elle, est significative, en particulier à cause des grands modèles de langage (LLM). La principale partie des dépenses énergétiques ont lieu en amont, dans l'entraînement initial de ces modèles, très coûteux en ressources (électricité, matériel spécialisé, eau, fonctionnement des centres de données et de calcul). Même si ce coût est mutualisé par un nombre important d'utilisateurs, il reste la composante la plus lourde de l'empreinte de ces outils et ne peut pas être simplement ignoré.

De plus, nos résultats ont montré une différence de qualité notable entre petits et grands modèles, ce qui incite indirectement à utiliser des modèles plus volumineux et donc plus coûteux en ressources. Pour un usage ponctuel comme dans notre projet, cet impact supplémentaire reste limité. En revanche, si ce type de pipeline était déployé de manière généralisée ou à grande échelle (augmentation des consultations, nombres très importants de contributions), l'empreinte cumulée pourrait devenir lourde.

Nous pouvons faire le même constat pour le choix de la métrique à utiliser : les traitements de la métrique QualIT, des métriques ROUGE et de la métrique NLI "à la main" sont locaux et assez peu coûteux, mais l'usage de la métrique NLI avec le modèle pré-entraîné repose sur un coût environnemental initial pour son entraînement. Il serait en principe possible de réduire cet impact en développant localement un modèle plus petit adapté spécifiquement à la consultation considérée. Toutefois, cela demande également du temps, des compétences, et des exemples déjà annotés, ce qui n'est pas forcément compatible avec les contraintes des consultations publiques, et peut même aller dans le sens inverse de l'objectif initial de gain de temps.

Ainsi, l'enjeu environnemental ne se situe pas seulement dans la consommation énergétique directe de notre projet, mais surtout dans l'écosystème dans lequel il s'inscrit à plus grande échelle : la diffusion et la banalisation de pratiques coûteuses (LLM, modèles pré-entraînés, traitements automatisés). Le fait qu'un usage isolé présente un faible impact environnemental ne suffit pas à blanchir un projet, dès lors qu'il contribue, même faiblement, à la banalisation d'outils augmentant la demande en ressources numériques et environnementales. Cela invite finalement à une sorte de responsabilité collective : choisir les modèles avec soin, les utiliser de manière réfléchie et sobre et garder en tête le rapport entre les bénéfices de leur utilisation et leur consommation à l'entraînement comme à l'utilisation.

4.4 Impact social global

À l'instar de l'impact environnemental, l'impact social direct de notre projet est assez faible. Notre travail n'a conduit à aucun déploiement d'outil de décision collective ou de dispositif disponible pour le grand public. Néanmoins, notre travail s'inscrit dans le projet *Perspectiva*, et plus largement dans le secteur des outils numériques pour l'analyse de consultations publiques, et, plus généralement

encore, il s'inscrit dans le développement de la démocratie participative à l'aide de méthodes computationnelles. Autrement dit, notre projet en lui-même n'a aucun impact social, mais l'écosystème plus général dans lequel il s'inscrit est intrinsèquement politique et peut avoir un impact social important.

À court terme, une perspective vertueuse pour ce type d'outil est d'accompagner la décision publique. Comme exposé en introduction, l'objectif n'est pas de remplacer les décideurs et analystes, mais de mieux transmettre les idées, préoccupations, et positions des citoyens, notamment lorsque le volume ou la longueur des contributions rend l'analyse manuelle lente, difficile et coûteuse. Ces outils aident ainsi à mieux écouter les individus et à restituer la parole collective de façon plus structurée. Ils peuvent aussi aider à redynamiser le débat public, notamment dans un contexte marqué par une défiance envers les institutions, de polarisation des discours, et où beaucoup ont le sentiment de ne plus être entendus. Mais ceci n'a de sens que si les résultats des consultations publiques sont réellement pris en compte et intégré à la prise de décision. À défaut, l'amélioration de ces outils risque de renforcer ce sentiment de consultation avant tout symbolique plutôt que réellement utile.

À plus long terme, ces outils peuvent aussi ouvrir de nouveaux horizons. Nous pouvons imaginer qu'ils participent à transformer les modèles de gouvernance actuels, vers des modèles plus horizontaux et plus participatifs. Bien sûr, ce ne sera pas forcément le cas, ni que ce serait souhaitable dans tous les contextes et tout le temps, mais développer des nouveaux dispositifs pour traiter automatiquement la parole citoyenne encourage la mise en œuvre de nouvelles possibilités politiques. En ce sens, nous pouvons voir cela comme une boîte que l'on ouvre : elle peut amener des avancées démocratiques (d'avantage d'inclusion, des débats plus riches, des consultations plus fréquentes, etc), au risque également de dérives (simplification des idées à l'extrême, délégation excessive, décision opaques, etc). Il est donc important de maintenir une certaine vigilance vis-à-vis du développement de ce type d'outils tout en l'encourageant.

Un premier enjeu central pour ces outils est celui de la représentativité. Même si les outils développés fonctionnent très bien, une consultation reste fragile si elle n'atteint qu'une petite partie de la population. Cela a notamment été reproché au Grand Débat National [Bli19, BGM20] et que nous avons pu constater à la lecture des contributions : certains groupes sociaux sont plus présents (retraités, diplômés, propriétaires, etc), sans doute, car plus à l'aise avec les formats de réponse proposés ou plus disponibles pour répondre. Dans ce contexte, les outils développés peuvent contribuer soit à réduire, soit au contraire à renforcer certains biais, leur impact dépendant moins de la qualité de l'extraction que de la composition sociale des contributeurs et contributrices. Il serait donc pertinent que les dispositifs de restitution intègrent, autant que possible, une réflexion explicite sur la représentativité des répondants (ou, a minima, un signalement des déséquilibres observés), afin de limiter le risque de présenter un point de vue socialement situé comme s'il représentait la « voix citoyenne » dans son ensemble.

La problématique de représentativité est étroitement liée à celle de la fracture numérique. Lorsque la collecte des contributions repose majoritairement sur des dispositifs en ligne, une partie de la population appelée à contribuer peut se retrouver mise de côté : ceux qui n'ont pas l'équipement, ceux qui ne sont pas à l'aise avec le numérique, ou les personnes âgées. Dans le cas du Grand Débat National sur lequel s'est appuyé notre projet, plusieurs modes de participation étaient mis à disposition : plateforme en ligne, mais également réunions publiques et cahiers en mairie, ce qui a permis de réduire l'impact de la fracture numérique. Mais de nouveau, dans ce contexte, ces outils doivent être utilisés tout en gardant cette problématique en tête, pour éviter d'exclure une partie de

la population du débat public et ainsi avoir un impact social positif.

Un second enjeu majeur concerne les biais potentiels liés au choix du LLM et, plus largement, des données sur lesquelles il a été entraîné. Les grands modèles de langage sont entraînés sur d’immenses corpus qui peuvent contenir, explicitement comme implicitement, des discours sexistes, racistes, classistes, etc. Un modèle pourrait, par exemple, mieux reconnaître ou valoriser certains de ces discours au détriment d’autres. Dans un contexte politique et notamment de décision publique, la façon dont sont construits les outils numériques utilisés peut avoir un impact important si ce type de biais passait sous le radar des métriques, influençant la synthèse finale et, finalement, les décisions publiques.

Un troisième enjeu important, au-delà des performances et des biais, est l’acceptabilité sociale de ces outils, qui dépend directement de leur transparence et de leur accessibilité. Dans des contextes politiques sensibles, il semble essentiel d’éviter que ces outils soient perçus comme des « boîtes noires » qui imposent des résultats sans explication. Pour que ces outils soient adoptés et puissent avoir un véritable impact, il est nécessaire que les objectifs, les limites, les étapes de traitement et les critères d’évaluation soient présentés et expliqués afin de créer une forme de confiance dans ces outils. Cependant, cette exigence de transparence ne doit pas se transformer en une technisation excessive du débat : il est tout aussi important de rendre ces outils compréhensibles et utilisables, sans exiger des utilisateurs (e.g. employés d’une mairie) des compétences avancées en code ou en apprentissage statistique. La simplicité de déploiement, la clarté des résultats et leur robustesse comptent autant que la qualité algorithmique pour que ces outils soient réellement utilisés.

Enfin, la question de la gestion des données et de leur hébergement constitue un enjeu social et politique important. Beaucoup de dispositifs respectent déjà un cadre réglementaire (notamment le RGPD), et ceci doit bien entendu être maintenu. Toutefois, ce n’est pas la problématique vis-à-vis des données de consultations publiques. L’utilisation de LLM à distance implique l’envoi de contributions citoyennes vers des infrastructures opérées par des entreprises privées, parfois situées à l’étranger. Dans un contexte de décision publique, cette utilisation peut soulever des questions de confidentialité, de dépendance technologique et, plus largement, de souveraineté numérique. Une alternative serait d’utiliser des modèles exécutés localement : ce qui réduirait les transferts de données, mais limiterait également l’accès aux modèles les plus performants. Ce compromis entre performance, maîtrise des données et autonomie est donc un point important pour le développement des outils numériques pour les consultations publiques.

En somme, l’impact social global de notre projet ne se situe pas dans ses effets immédiats qui sont concrètement nuls, mais dans les enjeux des outils plus généraux aux quels il se rattache. En s’inscrivant dans une réflexion plus large sur l’utilisation d’outils numériques pour la participation citoyenne, ce projet engage des questions de représentativité, de biais algorithmiques, de transparence des processus, d’accessibilité des outils et de souveraineté des données, qui peuvent tout autant avoir un impact social positif que négatif.

5 Conclusion

Remettre bout d’introduction sur l’objectif du projet.

Résultats globaux sur les métriques, la pipeline et l'impact du choix du LLM. Qu'est-ce qui peut encore être amélioré ou mieux détecté, quelles sont les limites actuelles ? Faire lien peut-être rapidement avec enjeux environnementaux et sociaux.

Ouverture :

- Bien entendu, le fait de se limiter à un échantillon de 200 contributions, ne permet pas de conclure définitive quant à la qualité des métriques que nous avons étudiées. Néanmoins, elles permettent de fournir une base pour une analyse comparative initiale. Les résultats que nous avons obtenus doivent être pris comme des indications préliminaires de la pertinence de chaque métrique, qui appellent potentiellement à être confirmées sur un échantillon de plus grande taille ou sur un sujet différent.
- En présence de sous-représentation d'une certaine frange de la population parmi les contributeurs, porter une attention toute particulière à ce que leurs idées soient bien conservées à l'étape des meta-idées.
- Choisir les seuils de la pipeline avec le "client". Souhaite-t-il uniquement garder les extractions de très grandes qualités au risque de perdre certaines idées et d'en avoir finalement assez peu, ou préfère-t-il plus d'idées de qualité légèrement plus faibles ?.
- Choisir les seuils en fonction de leur impact sur les meta-idées (deuxième partie du projet Perpectiva), étude à réaliser ensuite.
- Améliorations du prompt : meilleurs exemples d'extraction qui montre des erreurs de séparation d'idées ou d'hallucinations et exemples en lien avec le sujet de la consultation.

Références

- [AB22] Elisabeth Algava and Kilian Bloch. Vingt ans de participation électorale : en 2022, les écarts selon l'âge et le diplôme continuent de se creuser. <https://www.insee.fr/fr/statistiques/6658143>, 2022.
- [BCR26] Damien Bol, Bruno Cautrès, and Luc Rouban. La défiance envers les politiques en france approche un point de non-retour, selon le baromètre cevipof. *Le Monde*, 2026.
- [BGM20] Hamza Bennani, Pauline Gandré, and Benjamin Monnery. Les déterminants locaux de la participation numérique au grand débat national : une analyse économétrique. *Revue Economique*, 71 :715–737, 2020.
- [Bli19] Simon Blin. Un public éloigné des traits sociologiques des gilets jaunes. *Libération*, 2019.
- [BM19] Eric Buge and Camille Morio. Le grand débat national, apports et limites pour la participation citoyenne. *Revue du droit publique*, pages 1205–1238, 2019.
- [BNC26] Rasmus Blanck, Bill Noble, and Stergios Chatzikyriakidis. Reverse-engineering nli : A study of the meta-inferential properties of natural language inference. /, 2026.
- [Cou20] Dimitri Courant. La convention citoyenne pour le climat. une représentation délibérative. *Revue Projet*, 378 :60–64, 2020.
- [Cyr] François Cyril. Perspectiva - utiliser les outils llm pour analyser et fournir un retour plus rapide et fidèle aux contributeurs d'une consultation publique - enjeux sur la communication des résultats. https://docs.google.com/presentation/d/1z22FzVRVmvoVikUffME6vtDrgkIA5p9acvcq-KzoHZ0/edit?slide=id.g35890f26d4e_0_48#slide=id.g35890f26d4e_0_48.
- [Ins26] AI Objectives Institute. Talk to the city. <https://ai.objectives.institute/talk-to-the-city>, 2026.
- [KGB⁺24] Satya Kapoor, Alex Gil, Sreyoshi Bhaduri, Anshul Mittal, and Rutu Mulkar. Qualitative insights tool (qualit) : Llm enhanced topic modeling. /, 2024.
- [Lin04a] Chin-Yew Lin. Rouge : A package for automatic evaluation of summaries. In *Proceedings of the ACL Workshop on Text Summarization Branches Out*, pages 74–81, Barcelona, Spain, 2004.
- [Lin04b] Chin-Yew Lin. Rouge : A package for automatic evaluation of summaries. In *Proceedings of the Workshop on Text Summarization Branches Out (WAS 2004)*, 2004.
- [Rei25] Ehud Reiter. How to validate metric. <https://ehudreiter.com/2018/07/10/how-to-validate-metrics/>, 2025.
- [sit26] Data for good - bâtir un contre-pouvoir tech citoyen. <https://dataforgood.fr/>, 2026.
- [WTC26] E.Glen Weyl, Audrey Tang, and Plurality Community. Plurality : The future of collaborative technology and democracy. <https://www.plurality.net/v/eng/>, 2026.

6 Annexe

But: extraire les idées principales DISTINCTES d'un texte pour analyse.

Règles:

1. N'utiliser QUE le contenu entre «<TEXT >>.
2. Extraire la liste des idées DISTINCTES et PRINCIPALES.
 - Chaque idée = une phrase claire, autonome, reformulée si nécessaire.
3. Pour CHAQUE idée, annoter:
 - type: "statement" (constat) OU "proposition" (suggestion/recommandation/objectif).
 - syntax: "negative" si la phrase contient une négation explicite (ex.: "ne", "n'", "ne pas", "ne plus", "non"), sinon "positive".
 - semantic: "positive", "negative" ou "neutral" (valence sémantique).
4. Sortie STRICTEMENT en CSV avec entête EXACTE:
 - Délimiteur: virgule.
 - Chaque description entre guillemets doubles.
 - Chaque description entre guillemets doubles.
 - Échapper tout guillemet interne par duplication (ex.: ""chat"").
 - NE RIEN AJOUTER d'autre (pas de texte avant/après, pas de code fences).
 - Pas de lignes vides.

Exemple:

CSV:description,type,syntax,semantic

"Les chats retombent sur leurs pattes",statement,positive,neutral

"Les chats n'ont pas neuf vies",statement,negative,negative

"Il faut mieux prendre soin des chats pour prolonger leur vie",proposition,positive,positive

FIGURE 24 – Prompt utilisé pour l'extraction d'idées




FIGURE 25 – Distribution du score humain